

# Afinní šifra

Afinní šifra je substituční šifra, která vyměňuje jednotlivá písmena za jiná. Jedno písmeno se vždy transformuje na jiné (například A bude pokaždé K). Kvůli této vlastnosti bu zachována frekvence písmen před a po transformaci (jenom budou posunuty vrcholy). Důsledkem je, že je tato šifra náchylná na útok pomocí frekvenční analýzy.

## Šifrování

Šifrování vstupního řetězce probíhá dle uvedeného vzorce. Parametry “a” a “b” jsou zadány.

$$E(x) = (a * x + b) \% 26$$

Kde:

“a” je multiplikativní parametr (část klíče) “a”

“b” je aditivní parametr (část klíče) “b”

“x” je index písmena v abecedě (A = 0, B = 1, ...)

E(x) je zašifrovaný znak na indexu “x”

## Dešifrování

Dešifrování vstupního řetězce probíhá dle uvedeného vzorce. Parametry “a” a “b” jsou zadány.

$$D(x) = a^{-1}(x - b) \% 26$$

Kde:

“a<sup>-1</sup>” je multiplikativní inverze parametru (část klíče) “a”

“b” je aditivní parametr (část klíče) “b”

“x” je index písmena v abecedě (A = 0, B = 1, ...)

D(x) je dešifrovaný znak na indexu “x”

## Crack

Prolomení šifry bez znalosti klíče (parametry “a” a “b” nejsou zadány) je založeno na frekvenční analýze. Frekvenční analýza je založena na četnosti výskytu jednotlivých písmen v přirozeném jazyce (pro každý jazyk je jiná). Pokud víme, v jakém jazyce je zašifrovaný text, můžeme pomocí frekvenční analýzy provést odhad širovacích parametrů. Princip spočívá v tom, že písmena s vysokým výskytem v zašifrovaném textu budou pravděpodobně odpovídat nějakému znaku s vysokým výskytem (v našem případě) v češtině.

## Implementace

V projektu jsou implementovány dva způsoby útoku pomocí frekvenční analýzy. Oba vyžadují znalost frekvenčního histogramu češtiny (hodnoty převzaty z <https://nlp.fi.muni.cz/cs/FrekvenceSlovLemmat> ).

První přístup si určí dvě nejčastější písmena v češtině (jedná se o písmena “e” a “a”) a první dvě nejčastější písmena v zašifrovaném textu. (V mém případě bylo nutné prohodit první písmeno za druhé). Nyní můžeme pomocí indexů těchto písmen sestavit soustavu rovnic

$$\begin{aligned}c1 &== p1 * a + b \% 26; \\c2 &== p2 * a + b \% 26;\end{aligned}$$

Kde:

“c1, c2” jsou indexy zašifrovaných písmen

“p1, p2” jsou indexy odpovídajících písmen v otevřeném textu

Z této soustavy můžeme spočítat parametry “a” a “b”. Pokud budeme mít štěstí, budou to opravdu parametry, pomocí kterých byl text zašifrován a můžeme ho pomocí nich i rozšifrovat. Výhoda toho přístupu je rychlost, ale nevýhoda je horší robustnost, protože zvolená písmena si nemusí odpovídat. (například v mém případě byla prohozena frekvence prvního a druhého nejčastějšího písmene). Tato metoda je implementována ve funkci *crack()*.

Druhý přístup kombinuje frekvenční analýzu a brute force. Zkusíme zašifrovaný vstupní text rozšifrovat pomocí všech kombinací parametrů “a” a “b” (je jich  $12 * 26 = 312$ ) a pro každý takový “rozšifrovaný” text provedeme frekvenční analýzu (uděláme histogram s relativními četnostmi). Tento histogram porovnáme s histogramem češtiny a spočítáme, jak moc se liší. K tomu používám součet absolutních odchylek.

$$\text{Loss} = \sum_i^{26} \text{abs}(\text{histogram\_textu}[i] - \text{czech\_frequency}[i])$$

Průběžně si ukládám parametry “a” a “b” nejlepšího “rozšifrovaného” textu. Pro projití všech možností budou pravděpodobně parametry “a” a “b”, které vytvořily “rozšifrovaný” text nejpodobnější češtině správnými (de)šifrovacími parametry. Výhodou tohoto přístupu je vyšší robustnost (není třeba žádný odhad písmen), ale nevýhoda je vyšší časová složitost, protože v podstatě děláme brute force útok. Tato metoda je implementována ve funkci *crack\_BF()*.